
Erken Alzheimer Teşhisi için Görüntü İşleme ve Transfer Öğrenme Tabanlı Birleşik Bir Sınıflandırma Hattı

Mehmet DELİN - Yusuf Eren SEYREK - Muhammed Emir UYGUR

Öz

Alzheimer hastalığı, bunamanın en sık görülen biçimidir ve erken evrede saptanması tedavi planlaması açısından belirleyicidir. Bu çalışmada, beyin manyetik rezonans (MR) görüntülerinden dört evreli Alzheimer sınıflandırması için klasik görüntü işleme adımlarını bir araya getiren ve beş derin öğrenme mimarisini tek bir hatta karşılaştıran birleşik bir yaklaşım sunulmaktadır. Genel erişime açık Alzheimer MRI veri seti kullanılmış; 5120 eğitim ve 1280 test görüntüsü Mild_Demented, Moderate_Demented, Non_Demented ve Very_Mild_Demented olarak dört sınıfa ayrılmıştır. Ön işleme aşamasında kontrast sınırlı uyarlanabilir histogram eşitleme (CLAHE) uygulanmış, Otsu eşikleme ile beyin maskesi çıkarılmış ve dengesiz sınıf dağılımı Albumentations tabanlı veri çoğaltma ile sınıf başına 400 görüntüye dengelenmiştir. El yapımı özniteliklerle (HoG, yoğunluk istatistikleri, SIFT, GLCM) beslenen sınıf ağırlıklı bir Rastgele Orman karşılaştırma temeli olarak alınmış; ImageNet ön eğitilmiş beş ağ (ResNet18, VGG16, DenseNet121, EfficientNet-B0, MobileNetV3-Large) transfer öğrenme ile ince ayarlanmıştır. Test kümesinde en yüksek başarıyı ResNet18 (%63,98 doğruluk, 0,67 makro F1) ve DenseNet121 (%63,12 doğruluk, 0,66 makro F1) vermiştir. Rastgele Orman %57,89 doğruluk verirken VGG16 (%48,91), EfficientNet-B0 (%52,89) ve MobileNetV3 (%50,08) bu küçük ve dengesiz veri kümesinde klasik temelin altında veya yakınında kalmıştır. Grad-CAM ısı haritaları, en iyi modelin kararını verirken beyin dokusunun iç bölgelerine odaklandığını göstermiştir. Sonuçlar, sınırlı veri ile her derin mimarinin otomatik olarak klasik bir modeli geçmediğini; sade ve dengeli bir omurganın (ResNet18) bu koşulda öne çıktığını ortaya koymaktadır.

Anahtar kelimeler: Alzheimer, Manyetik rezonans görüntüleme, Evrişimli sinir ağı, Transfer öğrenme, ResNet, DenseNet, Grad-CAM.

Image Processing and a Comparative Evaluation of Five Deep Learning Architectures for Early Alzheimer's Diagnosis

Abstract: Alzheimer's disease is the most common form of dementia, and detecting it at an early stage shapes treatment planning. This study presents a unified pipeline that combines classical image processing steps and compares five deep learning architectures for four-class Alzheimer staging from brain magnetic resonance (MR) images. A publicly available Alzheimer MRI dataset was used, with 5120 training and 1280 test images split into four classes: Mild_Demented, Moderate_Demented, Non_Demented, and Very_Mild_Demented. During preprocessing, contrast limited adaptive histogram equalization (CLAHE) was applied, a brain mask was obtained through Otsu thresholding, and the imbalanced class distribution was balanced to 400 images per class with Albumentations-based augmentation. A class-weighted Random Forest fed with handcrafted features (HoG, intensity statistics, SIFT, GLCM) served as a baseline, while five ImageNet pre-trained networks (ResNet18, VGG16, DenseNet121, EfficientNet-B0, MobileNetV3-Large) were fine-tuned through transfer learning. On the test set, ResNet18 (63.98% accuracy, 0.67 macro F1) and DenseNet121 (63.12%, 0.66) performed best. The Random Forest reached 57.89%, whereas VGG16 (48.91%), EfficientNet-B0 (52.89%), and MobileNetV3 (50.08%) stayed below or near the classical baseline on this small and imbalanced

dataset. Grad-CAM heatmaps showed that the best model focused on inner brain tissue regions. The results indicate that, with limited data, not every deep architecture automatically outperforms a classical model, and a compact, balanced backbone (ResNet18) stands out under these conditions.

Keywords: Alzheimer, Magnetic resonance imaging, Convolutional neural network, Transfer learning, ResNet, DenseNet, Grad-CAM.

1. Giriş

Bunama, bilişsel işlevlerin yaşa bağlı beklenen düzeyin ötesinde bozulmasıyla ortaya çıkan bir sendromdur. Dünya Sağlık Örgütü'nün verilerine göre 2021 yılında dünya genelinde 57 milyon kişi bunama ile yaşamaktadır ve vakaların büyük bölümü düşük ve orta gelirli ülkelerde görülmektedir (World Health Organization, 2025). Aynı kaynak, Alzheimer hastalığının bunamanın en yaygın biçimi olduğunu ve tüm vakaların %60-70'ine katkı verdiğini bildirmektedir. Hastalığın erken evrede tanınması, hasta ve bakım verenler için tedavi sürecini ve yaşam planlamasını doğrudan etkiler.

Manyetik rezonans görüntüleme (MRG), beyin dokusunun yumuşak ayrıntılarını yüksek çözünürlükte sunduğu için Alzheimer değerlendirmesinde yaygın kullanılan bir yöntemdir. Ancak görüntülerin uzman tarafından tek tek incelenmesi zaman alıcıdır ve değerlendirmeler arasında farklılık görülebilir. Bu durum, radyologlara karar aşamasında yardımcı olabilecek bilgisayar destekli sınıflandırma sistemlerine olan ilgiyi artırmıştır.

Son yıllarda evrişimli sinir ağları (ESA), tıbbi görüntü sınıflandırmasında öne çıkan yöntem haline gelmiştir (LeCun ve ark., 2015). Sıfırdan eğitim çok sayıda etiketli görüntü ve yüksek hesaplama gücü gerektirdiğinden, tıbbi görüntülemede çoğunlukla transfer öğrenme tercih edilir. Bu yaklaşımda, ImageNet gibi büyük bir veri kümesinde eğitilmiş bir ağ (Deng ve ark., 2009; Russakovsky ve ark., 2015) yeni bir göreve uyarlanır (Pan ve Yang, 2010). Literatürde sıkça kullanılan omurgalar arasında artık bağlantılı ResNet (He ve ark., 2016), ardışık evrişim bloklarına dayalı VGG (Simonyan ve Zisserman, 2015), yoğun bağlantılı DenseNet (Huang ve ark., 2017), bileşik ölçeklemeli EfficientNet (Tan ve Le, 2019) ve hafif MobileNetV3 (Howard ve ark., 2019) yer alır.

Alzheimer sınıflandırması için literatürde çok sayıda transfer öğrenme çalışması bulunmaktadır. Francis ve Verma (2024), dikkat mekanizması eklenmiş bir ResNet-18 modeli ile MR görüntülerinden Alzheimer tespiti yapmıştır. Zia-ur-Rehman ve arkadaşları (2024), DenseNet-201 omurgasını transfer öğrenme ile kullanarak hastalığın farklı evrelerini ayırt etmiştir. Pandey ve arkadaşları (2024), ADNI ve OASIS veri kümeleri üzerinde ResNet-50, ResNet-101, ResNet-152, DenseNet-201 ve EfficientNet-B0 mimarilerini karşılaştırmıştır. Bu çalışmalar yüksek doğruluk değerleri raporlarsa da farklı mimarilerin aynı koşulda nasıl davrandığı, özellikle sınırlı veri ve dengesiz sınıf durumunda, daha az incelenmiştir.

Bu çalışma, bir lisans dönem projesi kapsamında işlenen görüntü işleme tekniklerini ve farklı sınıflandırma modellerini tek bir uçtan uca akışta birleştirmeyi amaçlamaktadır. Akış; ön işleme galerisi, Otsu tabanlı segmentasyon, veri çoğaltma ve bir klasik temel ile beş derin mimarinin aynı test kümesinde karşılaştırılmasından oluşmaktadır. Çalışmanın katkıları şunlardır:

- Klasik görüntü işleme adımları (CLAHE, kenar saptama, morfoloji, Otsu segmentasyon) ile farklı sınıflandırma yaklaşımlarının aynı veri kümesi üzerinde tek bir hatta toplanması.
- El yapımı öznitelik temelli Rastgele Orman ile beş ImageNet ön eğitilmiş mimarinin (ResNet18, VGG16, DenseNet121, EfficientNet-B0, MobileNetV3) aynı test kümesinde adil biçimde karşılaştırılması.

- Sınıf dengesizliğinin hem veri çoğaltma hem de sınıf ağırlıklı kayıp ile ele alınması.
- Grad-CAM ile en iyi modelin kararlarının görsel olarak yorumlanması.

2. Materyal ve Metot

Önerilen hat şu aşamalardan oluşur: veri yükleme, ön işleme ve segmentasyon, veri çoğaltma, klasik öznetelik temelli model, beş mimarının transfer öğrenme ile eğitimi ve son olarak Grad-CAM ile yorumlama. Deneyler Python 3.12 ve PyTorch 2.11 (Paszke ve ark., 2019), scikit-learn (Pedregosa ve ark., 2011), scikit-image (van der Walt ve ark., 2014) ve OpenCV kütüphaneleri ile, NVIDIA RTX 3050 Ti (4 GB) GPU üzerinde gerçekleştirilmiştir. Tekrarlanabilirlik için rastgelelik tohumu 42 olarak sabitlenmiştir.


2.1. Veri Seti

Çalışmada, Hugging Face platformunda açık erişimle paylaşılan Alzheimer MRI veri seti kullanılmıştır (Salieh, 2023). Veri seti 128×128 piksel boyutunda gri tonlamalı beyin MR görüntülerinden oluşur ve dört sınıf içerir. Toplam 6400 görüntü, kaynaktaki özgün ayırım korunarak 5120 eğitim ve 1280 test görüntüsüne bölünmüştür. Sınıf dağılımı Tablo 1'de verilmektedir.


Tablo 1. Eğitim ve test kümelerinde sınıf dağılımı.

Sınıf	Eğitim	Test
Mild_Demented	724	172
Moderate_Demented	49	15
Non_Demented	2566	634
Very_Mild_Demented	1781	459
Toplam	5120	1280

Tablo 1'de görüldüğü gibi dağılım belirgin biçimde dengesizdir. Non_Demented sınıfı eğitim kümesinin yarısına yakınına oluştururken, Moderate_Demented sınıfında yalnızca 49 eğitim görüntüsü bulunmaktadır. Bu dengesizlik, sınıflandırma başarımını doğrudan etkilediği için çalışmanın ilerleyen aşamalarında özel olarak ele alınmıştır.



Şekil 1. Her sınıfa ait örnek eğitim görüntüleri.




Şekil 2. Eğitim ve test kümelerinde sınıf dağılımının karşılaştırması.

2.2. Görüntü Ön İşleme

MR görüntülerinde kontrast farklılıkları ve gürültü, sonraki adımların başarımını etkiler. Ön işleme galerisinde temel teknikler tek bir görüntü üzerinde uygulanarak etkileri gösterilmiştir. Kontrast iyileştirme için histogram eşitleme ve kontrast sınırlı uyarlanabilir histogram eşitleme (CLAHE) kullanılmıştır. CLAHE, görüntüyü küçük bloklara bölerek yerel kontrastı sınırlı biçimde artırır ve düz histogram eşitlemenin yol açtığı aşırı kontrast sorununu azaltır (Zuiderveld, 1994). Gürültü azaltma için Gauss bulanıklaştırma uygulanmıştır.

Kenar ve yapı bilgisini incelemek amacıyla Sobel ve Laplacian gradyan operatörleri, Canny kenar saptayıcı (Canny, 1986) ve morfolojik gradyan kullanılmıştır. Bu adımların görsel sonuçları Şekil 3'te sunulmaktadır.




Şekil 3. Ön işleme teknikleri: histogram eşitleme, CLAHE, Gauss bulanıklaştırma, Sobel, Canny, Laplacian ve morfolojik gradyan.

2.3. Otsu Tabanlı Segmentasyon

Beyin bölgesinin arka plandan ayrılması için Otsu eşikleme yöntemi uygulanmıştır. Otsu yöntemi, sınıf içi varyansı en aza indiren eşik gri seviye histogramından otomatik olarak seçer (Otsu, 1979). Önce CLAHE ve Gauss bulanıklaştırma ile hazırlanan görüntüye Otsu eşik uygulanmış, ardından bağlı bileşen analizi ile en büyük bileşen beyin maskesi olarak alınmıştır. Maske, morfolojik kapama ve açma işlemleriyle düzeltilmiştir.


Maskenin içindeki dokuyu üç bölgeye ayırmak için çok seviyeli Otsu (multi-Otsu) eşikleme kullanılmıştır. Bu adım, beyin omurilik sıvısı, gri madde ve beyaz maddeye karşılık gelebilecek üç yoğunluk bölgesini renklendirerek görselleştirir. Segmentasyon adımlarının sonuçları Şekil 4'te yer almaktadır.



Şekil 4. Otsu tabanlı beyin maskesi ve çok seviyeli Otsu ile üç doku bölgesi.

2.4. Veri Çoğaltma ve Sınıf Dengeleme

Sınıf dengesizliğini gidermek için Alumentations kütüphanesi ile veri çoğaltma uygulanmıştır (Buslaev ve ark., 2020). Çoğaltma, derin öğrenmede aşırı uyumu azaltan ve genelleme başarımını artıran yerleşik bir tekniktir (Shorten ve Khoshgoftaar, 2019). Bu çalışmada yatay çevirme; sınırlı ölçekleme, öteleme ve döndürme içeren afin dönüşümler ve rastgele parlaklık-kontrast değişimi kullanılmıştır. Sınıf dengeleme iki yönlü yürütülmüştür: çok örnekli sınıflardan (Non_Demented, Very_Mild_Demented, Mild_Demented) rastgele 400 görüntü alt örneklenmiş, yalnızca 49 eğitim görüntüsü bulunan Moderate_Demented sınıfı ise CLAHE ile iyileştirilmiş görüntüler temel alınarak çoğaltma ile 400 örneğe tamamlanmıştır. Böylece her sınıfta 400, toplamda 1600 görüntü içeren dengeli bir eğitim kümesi elde edilmiştir. Test kümesi olduğu gibi bırakılmıştır. Örnek çoğaltma sonuçları Şekil 5'te gösterilmektedir.



Şekil 5. Alumentations ile uygulanan veri çoğaltma örnekleri.

2.5. Klasik Temel Model: El Yapımı Öznitelikler ve Rastgele Orman

Derin modellerle karşılaştırma temeli oluşturmak için el yapımı özniteliklere dayalı bir Rastgele Orman modeli kurulmuştur. Her görüntüden dört grup öznitelik çıkarılıp birleştirilmiştir:

- **HoG (Histogram of Oriented Gradients):** Yerel gradyan yönelimlerinin dağılımını betimler (Dalal ve Triggs, 2005).
- **Yoğunluk istatistikleri:** Ortalama, standart sapma, çarpıklık, basıklık ve entropi.
- **SIFT:** Ölçekten bağımsız anahtar nokta betimleyicilerinin ortalaması (Lowe, 2004).

- **GLCM (Gri Seviye Eş Oluşum Matrisi):** Kontrast, homojenlik, enerji ve korelasyon doku ölçütleri (Haralick ve ark., 1973).

Öznitelik çıkarımının hesaplama maliyetini sınırlamak amacıyla bu model, dengeli eğitim kümesinden sınıf başına 200 görüntü (toplam 800 örnek) içeren bir alt küme üzerinde eğitilmiştir. Öznitelikler standartlaştırıldıktan sonra 400 ağaçlı, sınıf ağırlıklı bir Rastgele Orman modeline verilmiştir (Breiman, 2001). Sınıf ağırlığı, dengesiz dağılımın etkisini azaltmak için "balanced" seçeneğiyle ayarlanmıştır.

2.6. Derin Öğrenme Modelleri: Beş Mimari

Beş ImageNet ön eğitilmiş mimari transfer öğrenme ile karşılaştırılmıştır. Her modelde omurganın büyük bölümü dondurulmuş, yalnızca son blok ve sınıflandırıcı katmanı ince ayarlanmıştır:

- **ResNet18 (He ve ark., 2016):** Son artık blok (layer4) ve sınıflandırıcı eğitilmiştir; 8.395.780 eğitilebilir parametre.
- **VGG16 (Simonyan ve Zisserman, 2015):** Tam bağlantılı sınıflandırıcı bloğu eğitilmiştir; 119.562.244 eğitilebilir parametre.
- **DenseNet121 (Huang ve ark., 2017):** Son yoğun blok (denseblock4), norm5 ve sınıflandırıcı eğitilmiştir; 2.164.228 eğitilebilir parametre.
- **EfficientNet-B0 (Tan ve Le, 2019):** Son evrişim bloğu ve sınıflandırıcı eğitilmiştir; 417.284 eğitilebilir parametre.
- **MobileNetV3-Large (Howard ve ark., 2019):** Son blok ve sınıflandırıcı eğitilmiştir; 1.390.724 eğitilebilir parametre.

Gri tonlamalı görüntüler üç kanala kopyalanmış ve ImageNet ortalama-standart sapma değerleriyle normalize edilmiştir. Sınıflandırıcı katmanlara aşırı uyumu azaltmak için 0,4-0,5 olasılıklı Dropout eklenmiştir. Sınıf dengesizliğini telafi etmek için sınıf ağırlıklı çapraz entropi kayıp fonksiyonu kullanılmıştır. Optimizasyon, öğrenme oranı 0,0001 ve ağırlık sönümü 0,0001 olan Adam ile yapılmıştır. Eğitim kümesi %80 eğitim ve %20 doğrulama olarak katmanlı biçimde ayrılmış, modeller 15 dönem (epoch) boyunca 16'lık yığınlarla eğitilmiş ve en yüksek doğrulama doğruluğunu veren ağırlıklar saklanmıştır.

2.7. Yorumlanabilirlik: Grad-CAM

En iyi modelin hangi bölgelere bakarak karar verdiğini incelemek için Grad-CAM yöntemi uygulanmıştır (Selvaraju ve ark., 2020). Grad-CAM, hedef sınıfın skorunun son evrişim bloğundaki aktivasyonlara göre gradyanını kullanarak bir ısı haritası üretir. Bu çalışmada ısı haritaları en yüksek doğruluğu veren modelin son evrişim bloğu üzerinden hesaplanmış ve özgün görüntünün üzerine bindirilmiştir.

2.8. Değerlendirme Ölçütleri

Modeller test kümesinde doğruluk (accuracy), kesinlik (precision), duyarlılık (recall) ve F1 skoru ile değerlendirilmiştir. Dört sınıfın dengesiz olması nedeniyle makro ortalama ve ağırlıklı ortalama değerleri birlikte raporlanmıştır. Ölçütler, doğru pozitif (TP), yanlış pozitif (FP), doğru negatif (TN) ve yanlış negatif (FN) sayıları üzerinden hesaplanır:

- Doğruluk = $(TP + TN) / (TP + TN + FP + FN)$
- Kesinlik = $TP / (TP + FP)$
- Duyarlılık = $TP / (TP + FN)$
- $F1 = 2 \times (Kesinlik \times Duyarlılık) / (Kesinlik + Duyarlılık)$

Ek olarak her model için karmaşıklık matrisi ve sınıf bazlı ROC eğrileri ile eğri altı alan (AUC) değerleri incelenmiştir.

3. Bulgular

3.1. Rastgele Orman Temel Modeli

El yapımı özniteliklere dayalı Rastgele Orman modeli, test kümesinde %57,89 doğruluk vermiştir. Sınıf bazlı sonuçlar Tablo 2'de sunulmaktadır. Model, çoğunluk sınıfı Non_Demented üzerinde 0,68 F1 ile en iyi başarıyı gösterirken, az örnekli Moderate_Demented sınıfında duyarlılığı 0,13'te kalmıştır. Makro F1 skoru 0,47'dir.


Tablo 2. Rastgele Orman modelinin sınıf bazlı sonuçları.

Sınıf	Kesinlik	Duyarlılık	F1
Mild_Demented	0,36	0,63	0,45
Moderate_Demented	1,00	0,13	0,24
Non_Demented	0,70	0,67	0,68
Very_Mild_Demented	0,56	0,45	0,50
Makro ort.	0,65	0,47	0,47
Doğruluk			0,58

3.2. Derin Modellerin Eğitimi

Beş mimari aynı dengeli eğitim kümesinde 15 dönem boyunca eğitilmiştir. GPU üzerinde eğitim süreleri ResNet18 için 25 saniye, DenseNet121 için 72 saniye, MobileNetV3 için 31 saniye, EfficientNet-B0 için 36 saniye ve VGG16 için 135 saniye olmuştur. En yüksek doğrulama doğrulukları sırasıyla ResNet18 0,781, DenseNet121 0,722, MobileNetV3 0,622, EfficientNet-B0 0,603 ve VGG16 0,650 olarak ölçülmüştür. Tüm modellerin eğitim ve doğrulama eğrileri Şekil 6'da verilmektedir. ResNet18 ve DenseNet121 eğrileri kararlı bir öğrenme sergilerken, VGG16 ve EfficientNet-B0 daha yavaş ve dalgalı bir yakınsama göstermiştir.

Şekil 6: Tüm Modellerin Eğitim Eğrileri



Şekil 6. Beş modelin eğitim ve doğrulama kayıp-doğruluk eğrileri.

3.3. Test Sonuçları ve Sınıf Bazlı Performans

Modellerin test kümesindeki sınıf bazlı sonuçları Tablo 3-7'de sunulmaktadır. En yüksek doğruluğu ResNet18 (%63,98) vermiş, onu DenseNet121 (%63,12) izlemiştir. Her iki model de az örnekli Moderate_Demented sınıfında yüksek F1 değerlerine (sırasıyla 0,84 ve 0,87) ulaşmıştır; bu, sınıf ağırlıklı kayıp ve veri dengeleme adımlarının etkisini gösterir. Buna karşın VGG16, EfficientNet-B0 ve MobileNetV3 daha düşük makro F1 değerlerinde kalmıştır.

Tablo 3. ResNet18 modelinin sınıf bazlı sonuçları.

Sınıf	Kesinlik	Duyarlılık	F1
Mild_Demented	0,48	0,71	0,57
Moderate_Demented	0,81	0,87	0,84

Sınıf	Kesinlik	Duyarlılık	F1
Non_Demented	0,73	0,72	0,73
Very_Mild_Demented	0,59	0,49	0,54
Makro ort.	0,65	0,70	0,67
Doğruluk			0,64

Tablo 4. VGG16 modelinin sınıf bazlı sonuçları.

Sınıf	Kesinlik	Duyarlılık	F1
Mild_Demented	0,24	0,64	0,35
Moderate_Demented	0,21	0,80	0,33
Non_Demented	0,67	0,69	0,68
Very_Mild_Demented	0,56	0,14	0,22
Makro ort.	0,42	0,57	0,40
Doğruluk			0,49

Tablo 5. DenseNet121 modelinin sınıf bazlı sonuçları.

Sınıf	Kesinlik	Duyarlılık	F1
Mild_Demented	0,44	0,59	0,50
Moderate_Demented	0,87	0,87	0,87
Non_Demented	0,75	0,68	0,71
Very_Mild_Demented	0,57	0,57	0,57
Makro ort.	0,66	0,68	0,66
Doğruluk			0,63


Tablo 6. EfficientNet-B0 modelinin sınıf bazlı sonuçları.

Sınıf	Kesinlik	Duyarlılık	F1
Mild_Demented	0,29	0,64	0,40
Moderate_Demented	0,15	0,47	0,22
Non_Demented	0,70	0,64	0,67
Very_Mild_Demented	0,55	0,34	0,42
Makro ort.	0,42	0,52	0,43
Doğruluk			0,53


Tablo 7. MobileNetV3-Large modelinin sınıf bazlı sonuçları.

Sınıf	Kesinlik	Duyarlılık	F1
Mild_Demented	0,33	0,60	0,43
Moderate_Demented	0,23	0,73	0,35
Non_Demented	0,67	0,51	0,58
Very_Mild_Demented	0,46	0,44	0,45
Makro ort.	0,42	0,57	0,45
Doğruluk			0,50

Karmaşıklık matrisleri Şekil 7'de, sınıf bazlı ROC eğrileri ise Şekil 8'de tüm modeller için sunulmaktadır. ROC eğrilerinde ResNet18 ve DenseNet121 için eğri altı alan (AUC) değerleri diğer modellere göre daha yüksektir.




Şekil 7. Beş model için karmaşıklık matrisleri.



Şekil 8. Beş model için sınıf bazlı ROC eğrileri ve AUC değerleri.

3.4. Grad-CAM ile Yorumlama

En iyi model (ResNet18) için elde edilen Grad-CAM ısı haritaları Şekil 9'da gösterilmektedir. Haritalar, modelin sınıf kararını verirken görüntünün kenarlarına değil beyin dokusunun iç bölgelerine yoğunlaştığını ortaya koymaktadır. Bu davranış, modelin arka plan veya kafatası kenarı gibi ilgisiz alanlardan çok anatomik yapıyı dikkate aldığını destekler.




Şekil 9. En iyi model (ResNet18) için her sınıfa ait Grad-CAM ısı haritaları ve model tahminleri.

3.5. Genel Karşılaştırma

Altı modelin test doğruluğu ve makro F1 skoru Tablo 8 ve Şekil 10'da karşılaştırılmaktadır. En yüksek başarıyı ResNet18 ve DenseNet121 vermiştir. Dikkat çekici biçimde, VGG16, EfficientNet-B0 ve MobileNetV3 klasik Rastgele Orman temelinin altında veya çok yakınında kalmıştır. Bu sonuç, sınırlı veri ve kısa eğitim koşulunda her derin mimarinin otomatik olarak klasik bir modeli geçmediğini göstermektedir.

Tablo 8. Altı modelin test kümesindeki doğruluk ve makro F1 karşılaştırması.

Model	Test Doğruluğu	Makro F1
ResNet18	0,6398	0,67
DenseNet121	0,6312	0,66
Rastgele Orman (öznitelik)	0,5789	0,47
EfficientNet-B0	0,5289	0,43
MobileNetV3-Large	0,5008	0,45
VGG16	0,4891	0,40



Şekil 10. Altı modelin test doğruluğu ve makro F1 karşılaştırması.

4. Tartışma

Bulgular, beş derin mimari ve bir klasik temel arasında belirgin bir başarımlar sıralaması ortaya koymaktadır. En yüksek doğruluğu ResNet18 (%63,98) ve DenseNet121 (%63,12) vermiş; bu iki model 0,67 ve 0,66 makro F1 ile Rastgele Orman temelini (0,47) açıkça geçmiştir. Buna karşın VGG16, EfficientNet-B0 ve MobileNetV3 daha düşük başarımlar göstermiş, hatta doğrulukta klasik Rastgele Orman temelini altında veya yakınında kalmıştır. Bu, "her derin model klasik bir modeli geçer" varsayımının sınırlı veri rejiminde geçerli olmadığını gösterir.

Mimariler arasındaki fark, eğitilebilir parametre sayısı ve ince ayar stratejisiyle açıklanabilir. ResNet18, görece az eğitilebilir parametresiyle (8,4 milyon) dengeli ve kararlı bir öğrenme sergilemiştir. DenseNet121, yoğun bağlantıları sayesinde 2,2 milyon parametreyle benzer bir başarıya ulaşmış ve az örnekli Moderate_Demented sınıfında en yüksek F1 değerini (0,87) vermiştir. VGG16 ise 120 milyon eğitilebilir parametreyle aşırı kapasiteye sahiptir; küçük bir veri kümesinde bu durum eğitimi zorlaştırmış ve dalgalı bir yakınsamaya yol açmıştır. EfficientNet-B0 ve MobileNetV3 yalnızca son blokları ince ayarlandığından, bu veriye yeterince uyum sağlayamamış olabilir; bu modellerin tam potansiyeli için daha kapsamlı ince ayar gerekebilir.

Grad-CAM analizi, en iyi modelin yorumlanabilirliği açısından destekleyici bir kanıt sunar. Isı haritalarının beyin dokusu üzerinde yoğunlaşması, modelin kararını anatomik içeriğe dayandığını gösterir. Bu tür görsel açıklamalar, klinik bağlamda güven oluşturma açısından önemlidir ve literatürdeki açıklanabilir yapay zeka çalışmalarıyla aynı yöndedir (Selvaraju ve ark., 2020).

Elde edilen doğruluk değerleri, literatürde aynı tür veri kümeleri için raporlanan %95 üzeri değerlerin altındadır (Francis ve Verma, 2024; Pandey ve ark., 2024; Zia-ur-Rehman ve ark., 2024). Bu farkın bir nedeni, çalışmanın hesaplama bütçesine uygun biçimde yalnızca son blokların ince ayarlanması ve görüntü çözünürlüğünün 128×128 ile sınırlı tutulmasıdır. Ayrıca önemli bir nokta, kullanılan veri kümesinin dilim (slice) düzeyinde rastgele bölünmüş olmasıdır: aynı hastaya ait komşu dilimlerin hem eğitim hem test kümesinde bulunması, çok yüksek doğruluk raporlayan çalışmalarda sonuçları iyimser gösterebilir. Bu çalışmadaki orta düzey doğruluklar, modellerin bu sızıntıyı büyük ölçüde sömürmediği daha dürüst bir tabloyu yansıtmaktadır.

Çalışmanın sınırlamaları açıktır. Moderate_Demented sınıfının test örneği sayısı yalnızca 15 olduğundan bu sınıfa ait metrikler yüksek değişkenlik taşır. Eğitim tek bir veri kümesi üzerinde yapıldığından modellerin farklı kaynaklardan gelen görüntülere genellenebilirliği sınanmamıştır. Sonuçların klinik geçerliliği için hasta düzeyinde ayrılmış bir bölünme ve çapraz doğrulama gereklidir.

5. Sonuç

Bu çalışmada, beyin MR görüntülerinden dört evreli Alzheimer sınıflandırması için görüntü işleme adımlarını ve altı sınıflandırma modelini birleştiren bir hat sunulmuştur. CLAHE tabanlı ön işleme, Otsu segmentasyon ve Albumentations ile veri dengeleme adımlarının ardından; el yapımı öznitelik temelli Rastgele Orman ile beş ImageNet ön eğitilmiş mimari (ResNet18, VGG16, DenseNet121, EfficientNet-B0, MobileNetV3) aynı test kümesinde karşılaştırılmıştır. En yüksek başarımlar %63,98 doğruluk ve 0,67 makro F1 ile ResNet18 sağlamış, DenseNet121 yakın bir sonuç vermiştir. VGG16, EfficientNet-B0 ve MobileNetV3 ise bu küçük ve dengesiz veri kümesinde klasik temelin altında veya yakınında kalmıştır. Grad-CAM ısı haritaları en iyi modelin beyin dokusuna odaklandığını göstermiştir.

İleriki çalışmalarda, daha yüksek çözünürlükte uçtan uca ince ayar, hasta düzeyinde k-kat çapraz doğrulama ve topluluk (ensemble) yöntemleri ile sonuçların güçlendirilmesi planlanmaktadır. Ayrıca

farklı veri kümeleri üzerinde değerlendirme, modellerin genellenebilirliğini ölçmek açısından yararlı olacaktır.

Yazarların Katkısı

Çalışmanın tüm aşamaları yazar tarafından gerçekleştirilmiştir.

Çıkar Çatışması Beyanı

Yazar, herhangi bir çıkar çatışması olmadığını beyan eder.

Araştırma ve Yayın Etiği Beyanı

Çalışmada araştırma ve yayın etiğine uyulmuştur. Kullanılan veri seti, Hugging Face platformunda açık erişimle paylaşılan anonim bir veri kümesidir.

Kaynaklar

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Buslaev, A., Iglovikov, V. I., Khvedchenya, E., Parinov, A., Druzhinin, M., & Kalinin, A. A. (2020). Albumentations: Fast and flexible image augmentations. *Information*, 11(2), 125. <https://doi.org/10.3390/info11020125>
- Canny, J. (1986). A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-8(6), 679–698. <https://doi.org/10.1109/TPAMI.1986.4767851>
- Dalal, N., & Triggs, B. (2005). Histograms of oriented gradients for human detection. *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, 886–893. <https://doi.org/10.1109/CVPR.2005.177>
- Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. *2009 IEEE Conference on Computer Vision and Pattern Recognition*, 248–255. <https://doi.org/10.1109/CVPR.2009.5206848>
- Francis, S. B., & Verma, J. P. (2024). Deep CNN ResNet-18 based model with attention and transfer learning for Alzheimer's disease detection. *Frontiers in Neuroinformatics*, 18, 1507217. <https://doi.org/10.3389/fninf.2024.1507217>
- Haralick, R. M., Shanmugam, K., & Dinstein, I. (1973). Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, SMC-3(6), 610–621. <https://doi.org/10.1109/TSMC.1973.4309314>
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778. <https://doi.org/10.1109/CVPR.2016.90>
- Howard, A., Sandler, M., Chu, G., Chen, L.-C., Chen, B., Tan, M., Vasudevan, V., Zhu, Y., Pang, R., & Adam, H. (2019). Searching for MobileNetV3. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 1314–1324. <https://doi.org/10.1109/ICCV.2019.00140>
- Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. Q. (2017). Densely connected convolutional networks. *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2261–2269. <https://doi.org/10.1109/CVPR.2017.243>
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Lowe, D. G. (2004). Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, 60(2), 91–110. <https://doi.org/10.1023/B:VISI.0000029664.99615.94>

- Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1), 62–66. <https://doi.org/10.1109/TSMC.1979.4310076>
- Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10), 1345–1359. <https://doi.org/10.1109/TKDE.2009.191>
- Pandey, P. K., Pruthi, J., Alzahrani, S., Verma, A., & Zohra, B. (2024). Enhancing healthcare recommendation: Transfer learning in deep convolutional neural networks for Alzheimer disease detection. *Frontiers in Medicine*, 11, 1445325. <https://doi.org/10.3389/fmed.2024.1445325>
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems*, 32, 8024–8035. <https://doi.org/10.48550/arXiv.1912.01703>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <https://jmlr.org/papers/v12/pedregosa11a.html>
- Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., ... Fei-Fei, L. (2015). ImageNet large scale visual recognition challenge. *International Journal of Computer Vision*, 115(3), 211–252. <https://doi.org/10.1007/s11263-015-0816-y>
- Salieh, F. G. (2023). *Alzheimer MRI dataset* [Veri seti]. Hugging Face. https://huggingface.co/datasets/Falah/Alzheimer_MRI
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2020). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *International Journal of Computer Vision*, 128(2), 336–359. <https://doi.org/10.1007/s11263-019-01228-7>
- Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on image data augmentation for deep learning. *Journal of Big Data*, 6(1), 60. <https://doi.org/10.1186/s40537-019-0197-0>
- Simonyan, K., & Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. *3rd International Conference on Learning Representations (ICLR)*. <https://doi.org/10.48550/arXiv.1409.1556>
- Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 97, 6105–6114. <https://doi.org/10.48550/arXiv.1905.11946>
- van der Walt, S., Schönberger, J. L., Nunez-Iglesias, J., Boulogne, F., Warner, J. D., Yager, N., Gouillart, E., & Yu, T. (2014). scikit-image: Image processing in Python. *PeerJ*, 2, e453. <https://doi.org/10.7717/peerj.453>
- World Health Organization. (2025). *Dementia* [Fact sheet]. <https://www.who.int/news-room/fact-sheets/detail/dementia>
- Zia-ur-Rehman, Awang, M. K., Rashid, J., Ali, G., Hamid, M., Mahmoud, S. F., Saleh, D. I., & Ahmad, H. I. (2024). Classification of Alzheimer disease using DenseNet-201 based on deep transfer learning technique. *PLOS ONE*, 19(9), e0304995. <https://doi.org/10.1371/journal.pone.0304995>